РОССИЙСКИЙ УНИВЕРСИТЕТ ДРУЖБЫ НАРОДОВ

Факультет физико-математических и естественных наук

Кафедра информационных технологий

ОТЧЕТ ПО ЛАБОРАТОРНОЙ РАБОТЕ № 1

Дисциплина: Методы машинного обучения

Студент: Кузнецов Юрий Владимирович

Группа: НФИбд-01-20

Москва 2023

Вариант №25

Индивидуальное задание:

1. Набор данных: forest_fires
2. Независимая переменная: features/FFMC
3. Зависимая переменная: features/temp
4. Визуализация для независимой переменной – столбчатая диаграмма
5. Визуализация для зависимой переменной – эмпирическая плотность распределения
6. Показатель качества регрессии – MSE (mean squared error)

Задание:

В соответствии с индивидуальным заданием, указанным в записной книжке команды, выполните следующие работы:

1. Загрузите заданный в индивидуальном задании набор данных из Tensorflow Datasets и оставьте в наборе данных признаки, принимающие непрерывные числовые значения, включая указанные в индивидуальном задании независимую и зависимую переменные. Вычислите матрицу корреляции признаков и определите пары признаков с наиболее низкой и наиболее высокой корреляцией.
2. Выполните визуализацию независимой и зависимой переменных в соответствии с индивидуальным заданием, подписывая оси и рисунок.
3. Постройте парную линейную регрессию для независимого и зависимого признаков при помощи точного подхода и при помощи нейронной сети с одним нейроном. Вычислите и сравните значения показателей качества R^2 двух подходов.
4. Постройте диаграмму рассеяния для независимого и зависимого признаков и изобразите линии двух построенных парных регрессий, подписывая оси и рисунок и создавая легенду.
5. Разбейте набор признаков на обучающую и контрольную выборки. Создайте и адаптируйте нормализующий слой Tensorflow для всех признаков набора данных (за исключением зависимого признака).
6. Используя созданный нормализующий слой, постройте регресоры на базе следующих моделей множественной регрессии:
    - линейной регрессии
    - гребневой регрессии (L2)
    - лассо регрессии (L1)
7. Определите на контрольной выборке модель множественной регрессии с наиболее высоким качеством по показателю, указанному в индивидуальном задании, среди построенных моделей.
8. Для лучшего регрессора визуализируйте кривые обучения (в зависимости от эпохи обучения).
9. Определите медианные значения признаков (кроме независимого и зависимого признаков) и для построенных медианных значений визуализируйте на плоскости с независимым признаком в качестве оси абсцисс и зависимым признаком в качестве оси ординат точки тестовой выборки и линии (графики) различных моделей множественной регрессии разными цветами. Подпишите оси и создайте легенду и заголовок для рисунка.

Решение:

Подключаем необходимые библиотеки:

```
import numpy as np
import pandas as pd
import tensorflow_datasets as tfds
import matplotlib.pyplot as plt
import tensorflow as tf
print(tf.__version__)
```

```
2.12.0
```

Считаем из TFDS набор данных **Forest Fires**:

```
ds = tfds.load("ForestFires", split='train')
```

Оставим в наборе данных признаки, принимающие непрерывные числовые значения, включая указанные в индивидуальном задании независимую и зависимую переменные.

```
df = tfds.as_dataframe(ds)
df.head()
```

	area	features/DC	features/DMC	features/FFMC	features/ISI	features/RH	features/X	features/Y	features
0	10.820000	671.200012	181.100006	96.099998	14.300000	63.0	7	5	
1	24.590000	750.500000	96.699997	90.500000	11.400000	55.0	3	4	
2	0.170000	607.099976	131.699997	94.300003	22.700001	55.0	6	5	
3	14.680000	671.200012	181.100006	96.099998	14.300000	27.0	3	4	
4	88.489998	699.599976	133.300003	92.900002	9.200000	21.0	4	4	

```
df.rename(columns={name: name.removeprefix('features/') for name in list(df.columns. values)}, inplace=True)
df.drop(columns=['rain'],inplace=True)
df.head()
```

	area	DC	DMC	FFMC	ISI	RH	X	Y	day	month	temp	wind
0	10.820000	671.200012	181.100006	96.099998	14.300000	63.0	7	5	1	7	27.299999	4.9
1	24.590000	750.500000	96.699997	90.500000	11.400000	55.0	3	4	6	8	20.600000	5.4
2	0.170000	607.099976	131.699997	94.300003	22.700001	55.0	6	5	1	7	19.400000	4.0
3	14.680000	671.200012	181.100006	96.099998	14.300000	27.0	3	4	1	7	32.299999	2.2
4	88.489998	699.599976	133.300003	92.900002	9.200000	21.0	4	4	2	8	26.400000	4.5

Вычислим матрицу корреляции признаков:

```
corr_arr = df.corr()
corr_arr
```

	area	DC	DMC	FFMC	ISI	RH	X	Y	day	month	temp	
area	1.000000	0.049383	0.072994	0.040122	0.008258	-0.075519	0.063385	0.044873	0.023226	0.056496	0.097844	0.01
DC	0.049383	1.000000	0.682192	0.330512	0.229154	-0.039192	-0.085916	-0.101178	0.000105	0.868698	0.496208	-0.20
DMC	0.072994	0.682192	1.000000	0.382619	0.305128	0.073795	-0.048384	0.007782	0.062870	0.466645	0.469594	-0.10
FFMC	0.040122	0.330512	0.382619	1.000000	0.531805	-0.300995	-0.021039	-0.046308	-0.041068	0.291477	0.431532	-0.02
ISI	0.008258	0.229154	0.305128	0.531805	1.000000	-0.132517	0.006210	-0.024488	0.032909	0.186597	0.394287	0.10
RH	-0.075519	-0.039192	0.073795	-0.300995	-0.132517	1.000000	0.085223	0.062221	0.092151	-0.095280	-0.527390	0.06
X	0.063385	-0.085916	-0.048384	-0.021039	0.006210	0.085223	1.000000	0.539548	-0.024922	-0.065003	-0.051258	0.01
Y	0.044873	-0.101178	0.007782	-0.046308	-0.024488	0.062221	0.539548	1.000000	-0.005453	-0.066292	-0.024103	-0.02
day	0.023226	0.000105	0.062870	-0.041068	0.032909	0.092151	-0.024922	-0.005453	1.000000	-0.050837	0.052190	0.03
month	0.056496	0.868698	0.466645	0.291477	0.186597	-0.095280	-0.065003	-0.066292	-0.050837	1.000000	0.368842	-0.08
temp	0.097844	0.496208	0.469594	0.431532	0.394287	-0.527390	-0.051258	-0.024103	0.052190	0.368842	1.000000	-0.22
wind	0.012317	-0.203466	-0.105342	-0.028485	0.106826	0.069410	0.018798	-0.020341	0.032478	-0.086368	-0.227116	1.00

Определим и выведем пары с наиболее низкой и наиболее высокой корреляцией соответственно:

```
features = df.columns.values.tolist()

min = 1
max = -1

for i in range(0, len(corr_arr)):
  for j in range(i+1, len(corr_arr)):
    if corr_arr.iloc[i, j] < min:
      min = corr_arr.iloc[i, j]
    if corr_arr.iloc[i, j] > max:
      max = corr_arr.iloc[i, j]

print('Минимальное значение корреляции: ', min)
print('Пара с наиболее низкой корреляцией:\n', features[5], '|', features[10])
print()
print('Максимальное значение корреляции: ', max)
print('Пара с наиболее высокой корреляцией:\n', features[1], '|', features[9])
```

```
Минимальное значение корреляции:  -0.5273903390408509
Пара с наиболее низкой корреляцией:
 RH | temp

Максимальное значение корреляции:  0.8686977623519123
Пара с наиболее высокой корреляцией:
 DC | month
```

Выполните визуализацию независимой и зависимой переменных в соответствии с индивидуальным заданием:

```
df['FFMC'].plot.bar(title='Столбчатая диаграмма независимой переменной FFMC', figsize=(15,6));
```

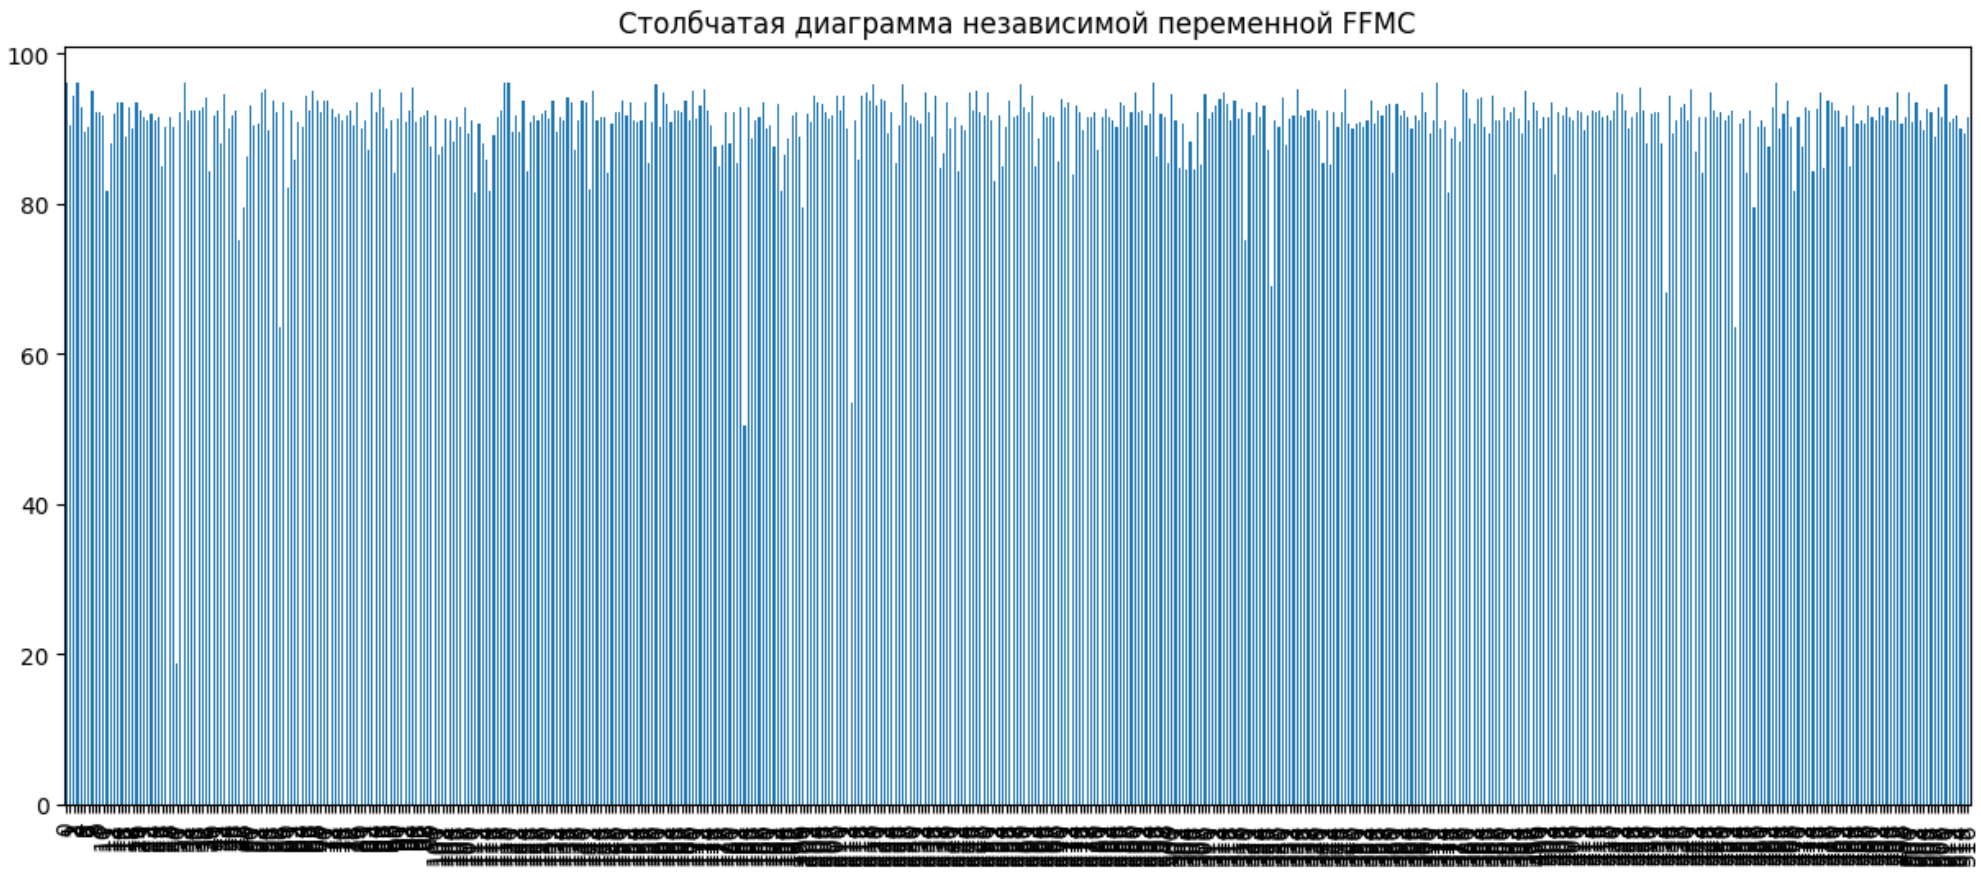


```
import seaborn as sns
```

```
sns.ecdfplot(data=df['temp'])

plt.xlabel('Температура')
plt.ylabel('Плотность')
plt.title('Эмпирическая плотность распределения для зависимой переменной temp')

plt.show()
```

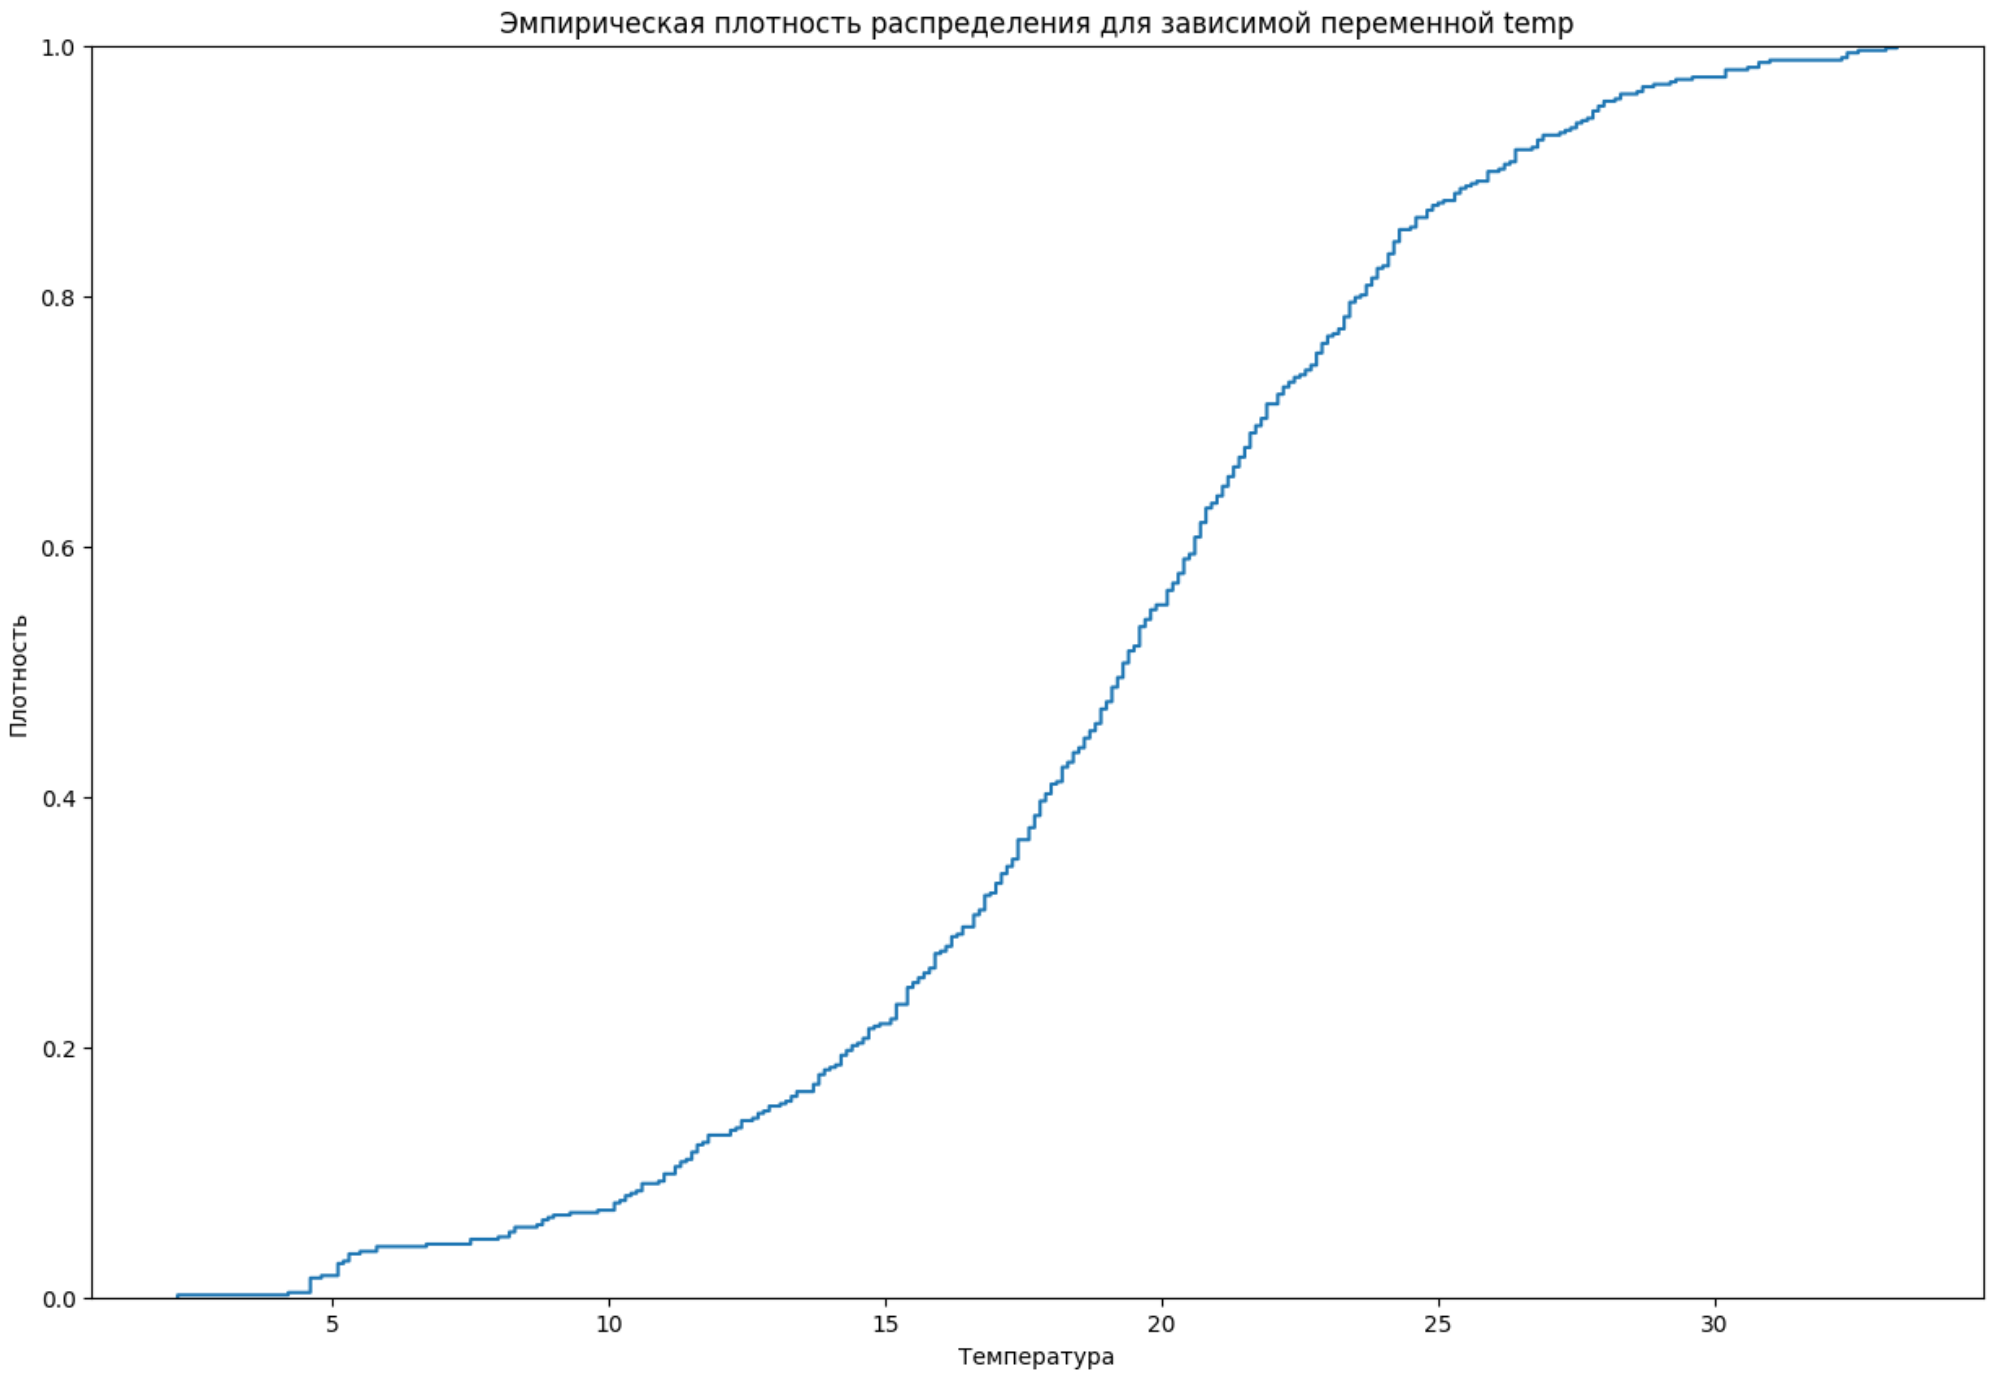

Построим парную линейную регрессию для независимого и зависимого признаков при помощи точного подхода и при помощи нейронной сети с одним нейроном. Вычислим и сравним значения показателей качества R2 двух подходов:

```
x = df['FFMC']
y = df['temp']

plt.scatter(x, y)
plt.grid()
plt.show()
```

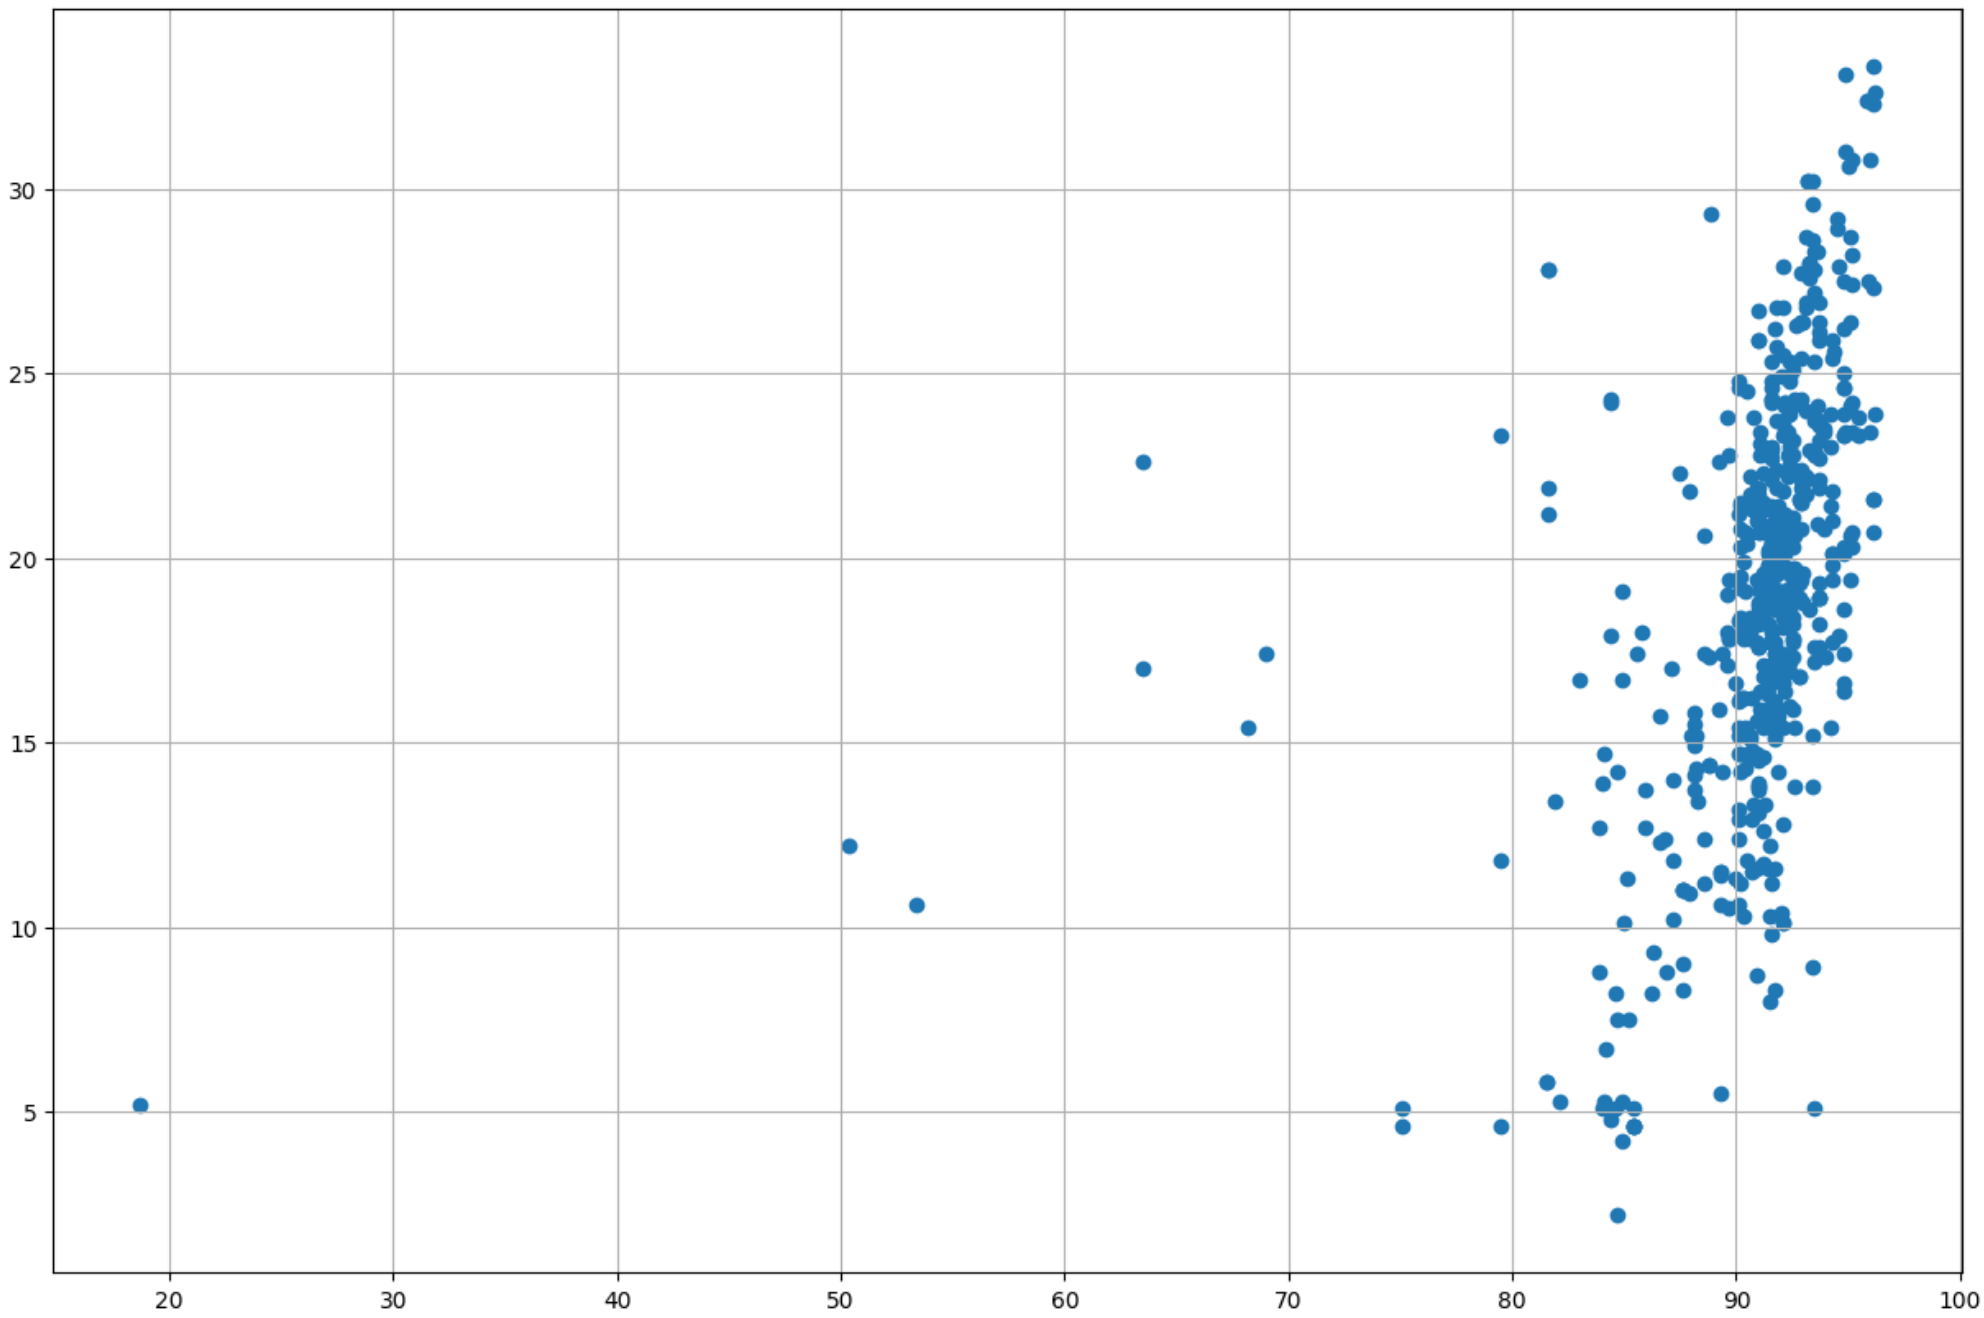


```
from sklearn.model_selection import train_test_split

X_train, X_test, y_train, y_test = train_test_split(x, y, test_size=0.25, shuffle=True)
```

```
class SimpleLinReg:
    def __init__(self):
        self.a_ = None
        self.b_ = None

    def fit(self, x_train, y_train):
        x_mean = np.mean(x_train)
        y_mean = np.mean(y_train)
        numerator = np.sum((x_train - x_mean) * (y_train - y_mean))
        denominator = np.sum((x_train - x_mean) ** 2)
        self.a_ = numerator / denominator
        self.b_ = y_mean - self.a_ * x_mean

    def predict(self, x_test):
        return self.a_ * x_test + self.b_


from sklearn.metrics import r2_score
from IPython.display import clear_output


from sklearn.metrics import mean_squared_error
```

```
slmodel = tf.keras.Sequential([tf.keras.layers.Dense(1, input_shape=(1,))])

slmodel.compile(
  loss=tf.keras.losses.mean_absolute_error,
  optimizer=tf.keras.optimizers.Adam(learning_rate=0.25),
  metrics=['mean_absolute_error']
)

slmodel.fit(X_train, y_train, epochs=20)
y_pred_net = slmodel.predict(X_test)

slreg = SimpleLinReg()
slreg.fit(X_train, y_train)

y_pred_reg = slreg.predict(X_test)

clear_output(wait=True)

r2_net = r2_score(y_test, y_pred_net)
r2_reg = r2_score(y_test, y_pred_reg)

print('Метрика R2 сети с одним нейроном:', r2_net)
print('Метрика R2 парной линейной регрессии:', r2_reg)
```

```
    Метрика R2 сети с одним нейроном: 0.13457095091352034
    Метрика R2 парной линейной регрессии: 0.19300862369703686
```

Построим диаграмму рассеяния для независимого и зависимого признаков и изобразим линии двух построенных парных регрессий:

```
plt.scatter(x, y, label='Выборка')
plt.plot(x, slreg.predict(x), color='purple', label='Парная линейная регрессия')

plt.plot(x, slmodel.predict(x), color='red', label='Сеть с одним нейронном')
clear_output(wait=True)
plt.legend()

plt.title('Результаты обучения')
plt.xlabel("FFMC")
plt.ylabel("temp")

plt.show()
```

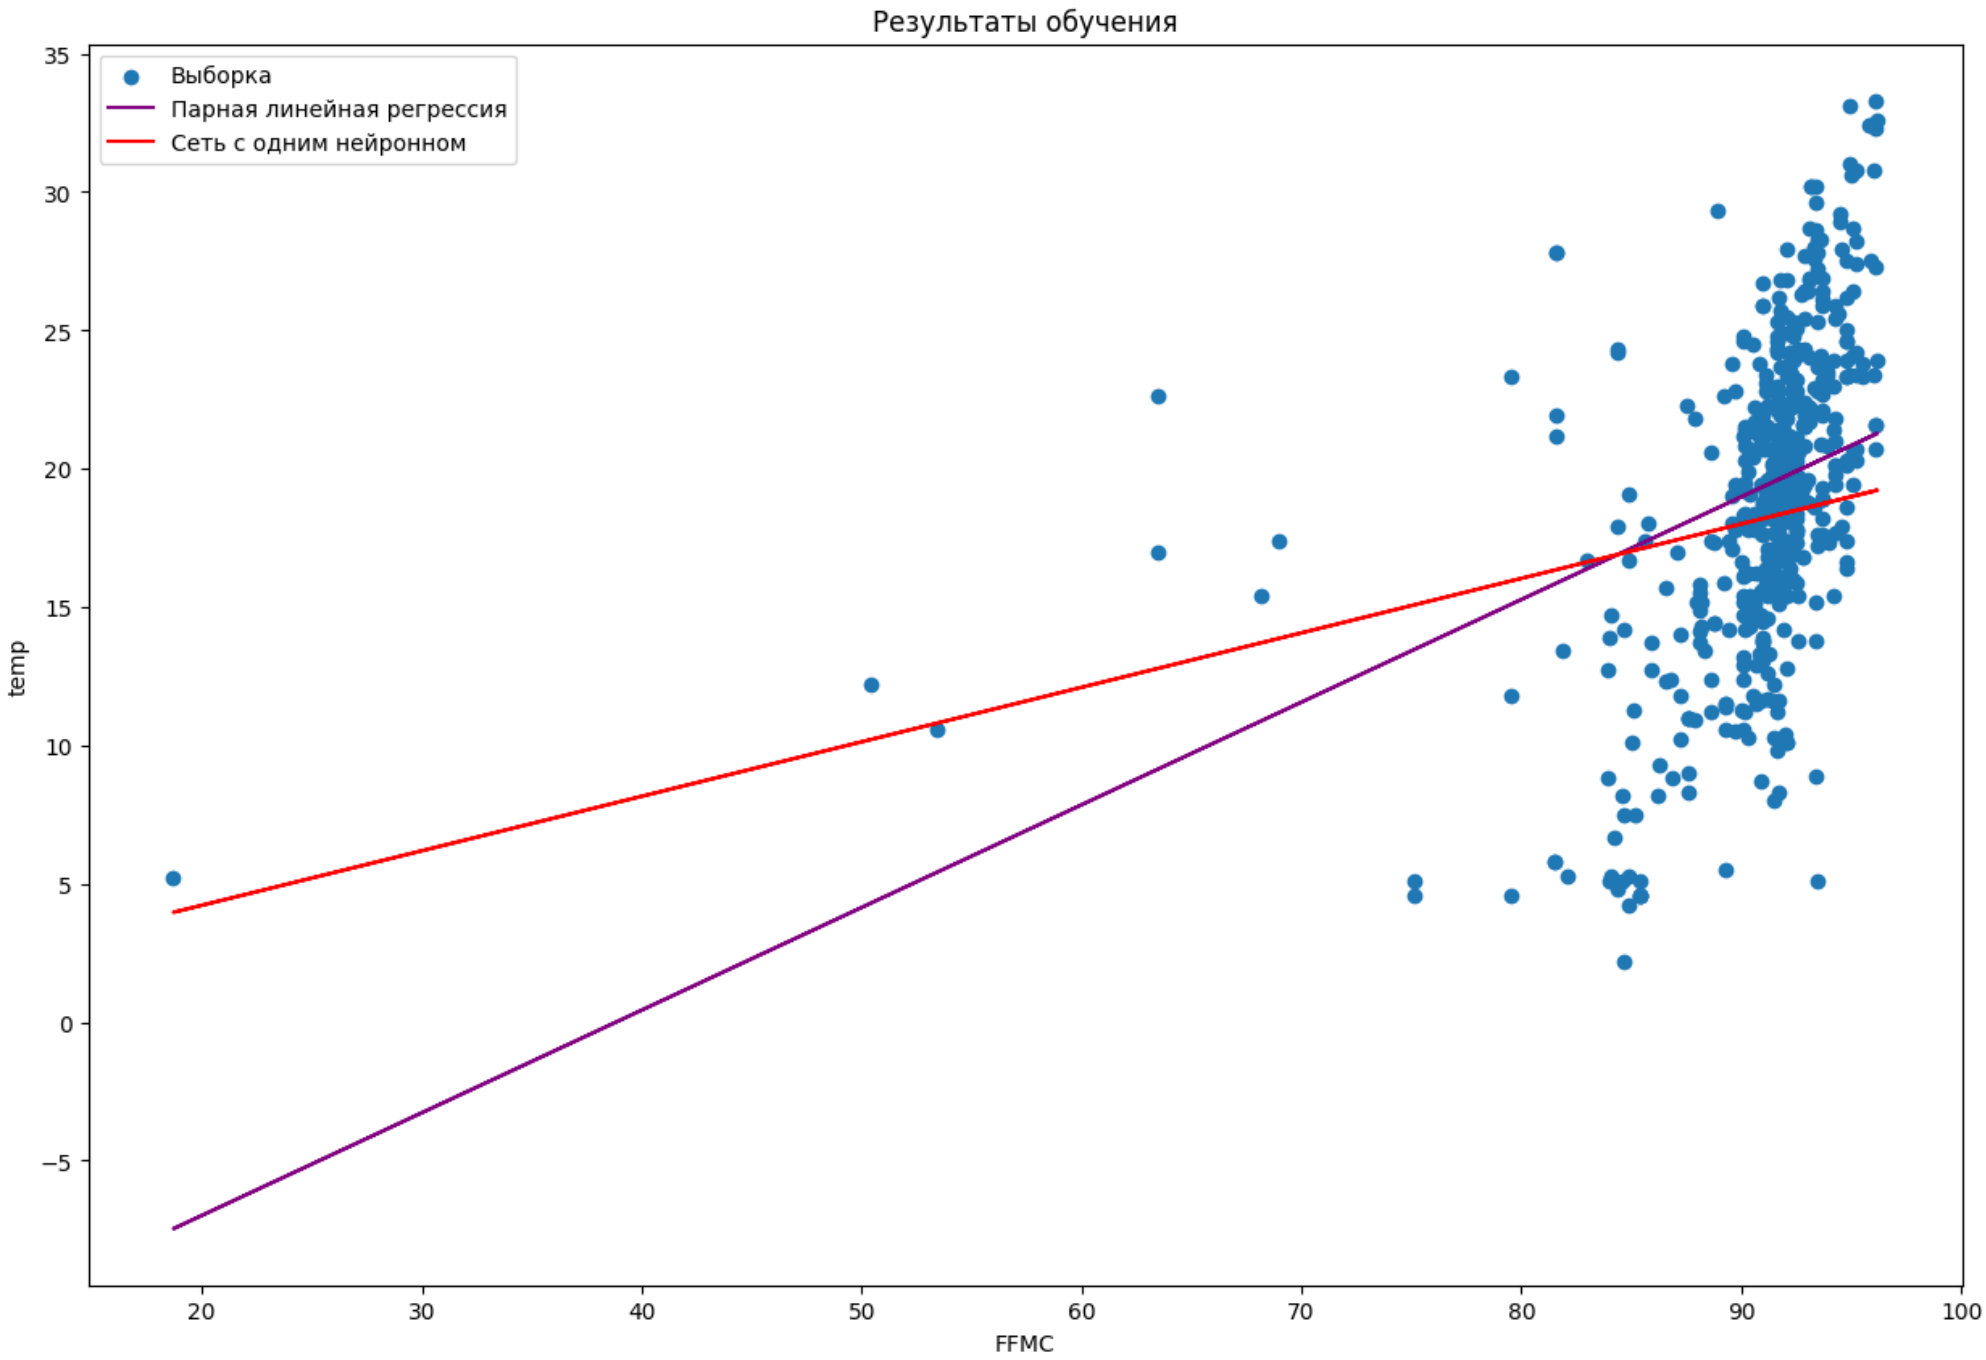

Разобьём набор признаков на обучающую и контрольную выборки. Создадим и адаптируем нормализующий слой Tensorflow для всех признаков набора данных (за исключением зависимого признака):

```
X = df.drop(columns=['temp'])
y = df['temp']

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.25, shuffle=True)

normalizer = tf.keras.layers.Normalization()
normalizer.adapt(X_train)
```

Используя созданный нормализующий слой, построим регресоры на базе следующих моделей множественной регрессии:

- линейной регрессии
- гребневой регрессии (L2)
- лассо регрессии (L1)

```
model_LN = tf.keras.Sequential([
    normalizer,
    tf.keras.layers.Dense(1)
])

model_LN.compile(
    loss=tf.keras.losses.mean_absolute_error,
    optimizer=tf.keras.optimizers.Adam(learning_rate=1e-1),
    metrics=['mean_absolute_error']
)

history_LN = model_LN.fit(
    X_train, y_train,
    epochs=64,
    validation_split = 0.2
)

clear_output()


model_L1 = tf.keras.Sequential([
    normalizer,
    tf.keras.layers.Dense(1, kernel_regularizer=tf.keras.regularizers.L1(l1=0.01))
])

model_L1.compile(
    loss=tf.keras.losses.mean_absolute_error,
    optimizer=tf.keras.optimizers.Adam(learning_rate=1e-1),
    metrics=['mean_absolute_error']
)

history_L1 = model_L1.fit(
    X_train,
    y_train,
    epochs=64,
    validation_split = 0.2
)

clear_output()
```

```
model_L2 = tf.keras.Sequential([
    normalizer,
    tf.keras.layers.Dense(1, kernel_regularizer=tf.keras.regularizers.L2(l2=1e-5))
])

model_L2.compile(
    loss=tf.keras.losses.mean_absolute_error,
    optimizer=tf.keras.optimizers.Adam(learning_rate=1e-1),
    metrics=['mean_absolute_error']
)

history_L2 = model_L2.fit(
    X_train,
    y_train,
    epochs=64,
    validation_split = 0.2
)

clear_output()
```

Определим на контрольной выборке модель множественной регрессии с наиболее высоким качеством по показателю, указанному в индивидуальном задании, среди построенных моделей:

```
y_pred_LN = model_LN.predict(X_test, verbose=0)

print(r'Метрика линейной регрессии: %.4f' % r2_score(y_test, y_pred_LN))

y_pred_L1 = model_L1.predict(X_test, verbose=0)

print(r'Метрика лассо регрессии: %.4f' % r2_score(y_test, y_pred_L1))

y_pred_L2 = model_L2.predict(X_test, verbose=0)

print(r'Метрика гребневой регрессии: %.4f' % r2_score(y_test, y_pred_L2))
```

```
    Метрика линейной регрессии: 0.6558
    Метрика лассо регрессии: 0.6591
    Метрика гребневой регрессии: 0.6638
```

Для лучшего регрессора визуализируем кривые обучения:

```
def plot_loss(history):
  plt.plot(history.history['loss'], label='Loss')
  plt.plot(history.history['val_loss'], label='Validation Loss')
  plt.title('Кривые обучения')
  plt.xlabel('Эпохи обучения')
  plt.ylabel('Ошибка')
  plt.legend()
  plt.grid(True)

plot_loss(history_L1)
```

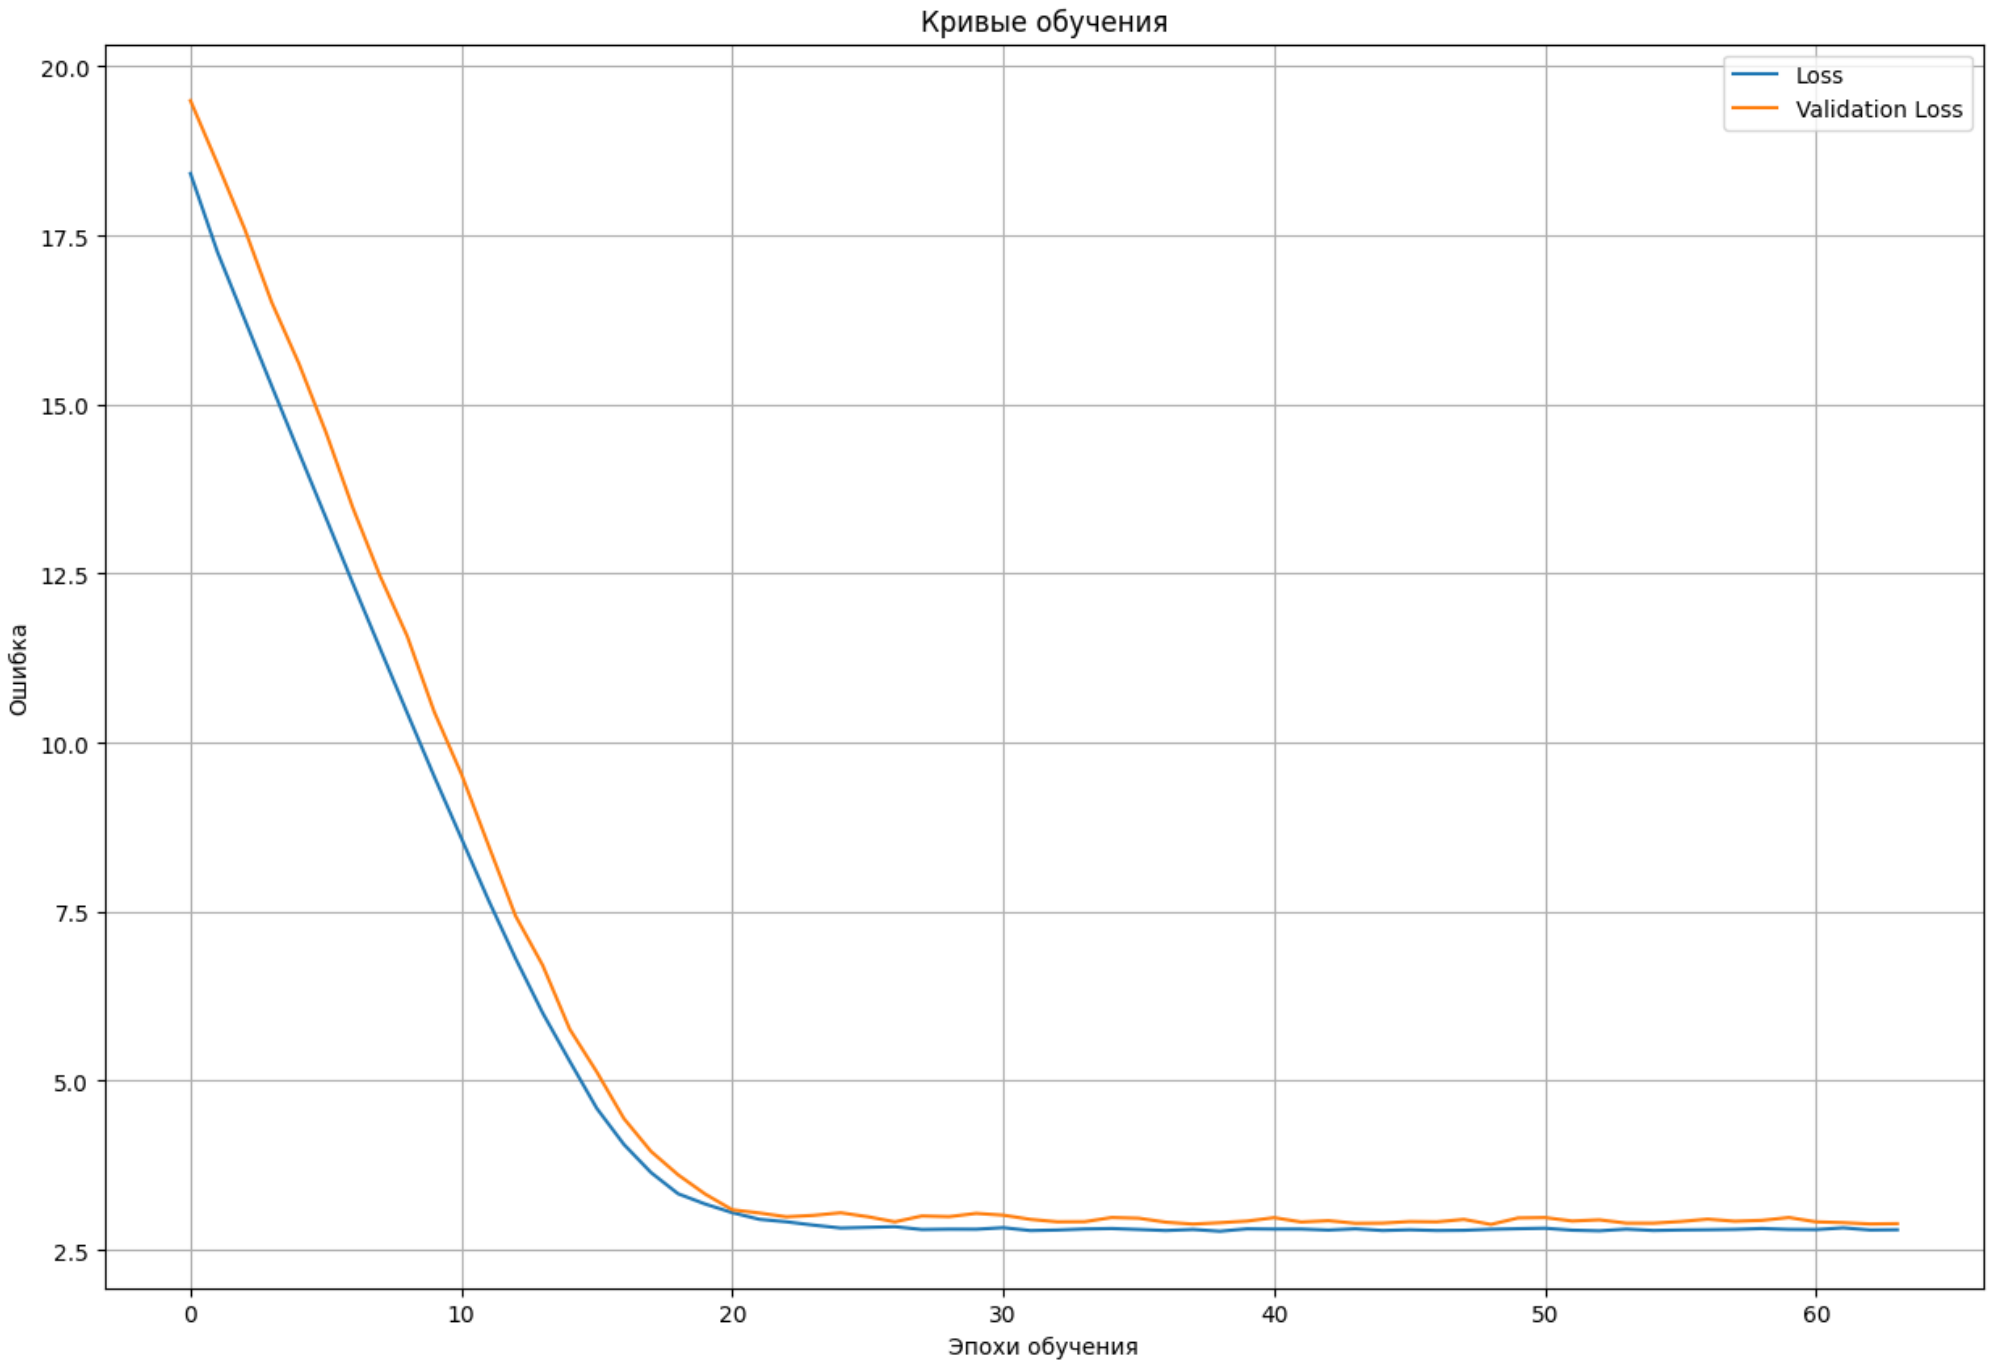

Определим медианные значения признаков (кроме независимого и зависимого признаков) и для построенных медианных значений визуализируем на плоскости с независимым признаком в качестве оси абсцисс и зависимым признаком в качестве оси ординат точки тестовой выборки и линии (графики) различных моделей множественной регрессии разными цветами:

```
features_independent = X_test['FFMC']
features_dependent = y_test
features_other = X_test.drop(columns=['FFMC'])
```

```
X_plot = X_test.copy()
features_other_md = pd.DataFrame(features_other.median()).T
for key in features_other_md:
  X_plot[key] = float(features_other_md[key])
X_plot.head()
```

	area	DC	DMC	FFMC	ISI	RH	X	Y	day	month	wind
232	0.385	650.599976	103.850006	90.599998	8.299999	41.0	4.0	4.0	4.0	7.0	4.0
504	0.385	650.599976	103.850006	89.699997	8.299999	41.0	4.0	4.0	4.0	7.0	4.0
14	0.385	650.599976	103.850006	93.599998	8.299999	41.0	4.0	4.0	4.0	7.0	4.0
213	0.385	650.599976	103.850006	53.400002	8.299999	41.0	4.0	4.0	4.0	7.0	4.0
436	0.385	650.599976	103.850006	89.300003	8.299999	41.0	4.0	4.0	4.0	7.0	4.0

```
plt.rcParams["figure.figsize"] = [15, 10]
plt.scatter(features_independent, features_dependent, label='Выборка')

plt.plot(features_independent, model_LN.predict(X_plot, verbose=0), color='gree
plt.plot(features_independent, model_L1.predict(X_plot, verbose=0), color='purp
plt.plot(features_independent, model_L2.predict(X_plot, verbose=0), color='red'

plt.title('Визуализация результата обучения')
plt.xlabel('FFMC')
plt.ylabel('temp')
plt.legend()
plt.grid(True)

plt.show()
```